ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN MÔN HỌC

Hệ thống Hỏi – Đáp Đọc hiểu Văn bản bằng Giọng nói Tiếng Việt

ViMMRC Voice Q&A · STT → Truy xuất 2 tầng → vi-mrc-large → Matcha-TTS, chạy trên CPU

Hỏi bằng giọng nói · Tìm đoạn văn · Đọc hiểu · Trả lời bằng giọng nói

Ngô Trí Huy
Nhóm trưởng · Truy xuất, Đọc hiểu, Hội thoại, API

Huỳnh Công Lương
Nhận dạng giọng nói (STT) · Web · Docker

Trương Hoàng Duy
Tổng hợp giọng nói (TTS) · Đánh giá âm học

Giảng viên hướng dẫn: **Hà Minh Tân** · Môn học: **Học máy tiên tiến và ứng dụng**

Hỏi bằng giọng nói, nghe câu trả lời có căn cứ

ĐẦU VÀO

Câu hỏi nói tự nhiên bằng tiếng Việt, không kèm đoạn văn

HỆ THỐNG

Tự tìm đoạn văn liên quan, đọc hiểu và soạn câu trả lời

ĐẦU RA

Câu trả lời trọn câu bằng giọng nói, kèm đoạn văn làm bằng chứng

Vì sao cần kênh giọng nói

ViMMRC, ViQuAD được xây cho tương tác bằng văn bản.

- Khi không tiện nhìn màn hình, gõ phím
- Người khiếm thị
- Lớp học, kiosk học đường

Mục tiêu đo được

STT

WER thấp hơn Whisper gốc

Truy xuất

Recall@1 cao trên kho lớn

Đọc hiểu

EM và token F1 trên test

TTS

CER thấp, nhanh hơn thời gian thực

Ràng buộc: chạy trên CPU, có thể offline, từ chối khi thiếu căn cứ

Các nền tảng mà đề tài kế thừa ở từng chặng

STT

Whisper

Radford và cs., 2023

LoRA

Hu và cs., 2022

VietSpeech · ViWhisper

Pham và cs., 2024

faster-whisper · CTranslate2

SYSTRAN; OpenNMT

Truy xuất

BM25

Robertson & Zaragoza, 2009

Dense Passage Retrieval

Karpukhin và cs., 2020

Multilingual E5

Wang và cs., 2024

Rerank BERT · BGE-M3

Nogueira & Cho, 2019; Chen và cs., 2024

Đọc hiểu

T5 text-to-text

Raffel và cs., 2020

ViT5

Phan và cs., 2022

ViMMRC 2.0

UIT NLP, 2023

UIT-ViQuAD2.0

dữ liệu Hugging Face, 2023

TTS

Flow Matching

Lipman và cs., 2023

Matcha-TTS

Mehta và cs., 2024

Glow-TTS · MAS

Kim và cs., 2020

HiFi-GAN

Kong và cs., 2020

Mỗi thành phần đã có công bố riêng. Đề tài ghép chúng thành một chuỗi hỏi – đáp bằng giọng nói tiếng Việt chạy trên CPU và điều chỉnh từng khâu cho tiếng Việt.

Chu trình hỏi – đáp 4 chặng, dự phòng đa tầng

CHẶNG 1 · STT

Whisper-small LoRA

- 50 giờ VietSpeech
- CTranslate2 INT8 · VAD

13,77%

WER (gốc 36,76%)

CHẶNG 2 · RETRIEVAL

BM25 + Dense + Rerank

- 5.879 đoạn + 1,48 tr. Wiki
- bge-reranker-v2-m3

85,9%

Recall@5 BM25 2 tầng (R@1 71,1%)

CHẶNG 3 · MRC

vi-mrc-large (trích span)

- Trích đáp án từ đoạn văn
- chọn trong 9 ứng viên

0,468

F1 câu nói (ViT5 0,446)

CHẶNG 4 · TTS

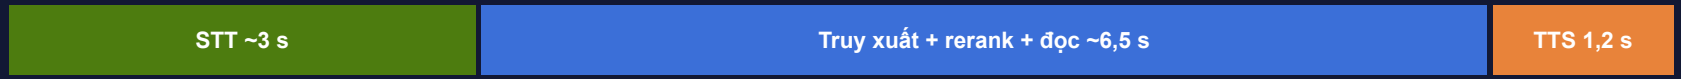
Matcha-TTS (OT-CFM)

- 10–20 bước Euler, CPU
- 41 token tách thanh điệu

0,8%

CER (giọng thật 0,7%)

Độ trễ mỗi câu · Docker CPU 4 luồng — **≈ 10,6 s (tắt reranker ≈ 5,1 s)**



PHẦN I · TỔNG HỢP GIỌNG NÓI (TTS)

Tổng hợp tiếng nói Matcha-TTS và HiFi-GAN

Trình bày: Trương Hoàng Duy

0,8%
CER, giọng thật 0,7%

0,88
log-F0 RMSE (bán cung)

0,53–0,64
RTF trên CPU 8 luồng

41 token
tách thanh điệu, −58,2%

Trình bày: Trương Hoàng Duy

Tổng hợp giọng Việt: nhanh trên CPU mà vẫn đúng thanh điệu

Bối cảnh

- 6 thanh điệu quyết định nghĩa của từ
- Câu trả lời chứa nhãn đáp án, số, ngày tháng, đơn vị
- Cần chạy CPU, có thể offline để bảo mật dữ liệu

Các hướng tiếp cận đã khảo sát

Hướng / công trình	Điểm mạnh	Hạn chế với đề tài
VITS MMS *Pratap và cs., 2023*	Đa ngôn ngữ, chạy cục bộ	Thanh điệu còn gượng, CER 4,7%
Diffusion TTS *mô hình khuếch tán*	Chất lượng cao	Hàng trăm bước giải, chậm trên CPU
Glow-TTS · MAS *Kim và cs., 2020*	Tự căn chỉnh, không cần nhãn thời lượng	Bản cài đặt gốc cần biên dịch C++
Matcha-TTS + HiFi-GAN *Mehta và cs., 2024; Kong và cs., 2020*	10–20 bước, mô hình ~20 triệu tham số	**Chọn · cần dữ liệu và frontend tiếng Việt**

Nguồn: Báo cáo TTS, chương 1, 3, 6 và tài liệu tham khảo

Matcha-TTS tiếng Việt với frontend tách thanh điệu

THÁCH THỨC	GIẢI PHÁP CỦA NHÓM
Phải nhanh hơn thời gian thực trên CPU	**Matcha-TTS (OT-CFM), học chuyển giao từ tiếng Anh**
Thanh điệu dễ sai, dữ liệu thưa	**Tách dấu thành 6 token: còn 41 ký hiệu**
Vocoder tổng quát gây rè kim loại	**Tinh chỉnh HiFi-GAN trên phổ Mel do Matcha sinh**
Văn bản có nhãn, số, ngày tháng	**Chuẩn hóa văn bản, chèn khoảng nghỉ theo dấu câu**
Cài đặt khó, dễ gián đoạn	**MAS bằng Numba; 4 engine dự phòng**

Kết quả

0,8%
CER (giọng thật 0,7%)

0,88
log-F0 RMSE bán cung

0,53–0,64
RTF trên CPU

Trình bày: Trương Hoàng Duy

Đọc đúng 6 thanh điệu, nhanh hơn thời gian thực trên CPU

Ngữ âm chính xác
6 thanh, ngắt nghỉ theo dấu câu

Tài nguyên thấp
RTF < 1 trên CPU, không GPU

Văn bản đặc thù
nhãn đáp án, số, ngày, đơn vị

Tự chủ
chạy offline, dự phòng đa tầng

Sáu đóng góp

1. Matcha-TTS tiếng Việt, học chuyển giao, InfoRe1 25 giờ
2. Tách thanh điệu: 41 token (−58,2%)
3. MAS viết lại bằng Numba JIT
4. HiFi-GAN tinh chỉnh 50k bước trên Mel nhân tạo
5. Chuẩn hóa văn bản + điều phối 4 engine
6. Đo MCD, F0, log-F0, CER, RTF; so với VITS MMS

Sáu giai đoạn từ văn bản đến tệp âm thanh

1 · Chuẩn hóa

Markdown, (B) → “Đáp án B:”, số → chữ

2 · Phân cụm

cắt theo , ; : . ! ? xuống dòng

3 · Token + thanh

dấu thanh ra cuối âm tiết, 41 token

4 · Matcha-TTS

OT-CFM 10–20 bước → Mel 80 kênh

5 · HiFi-GAN

vocoder + denoiser → 22,05 kHz

6 · Hậu xử lý

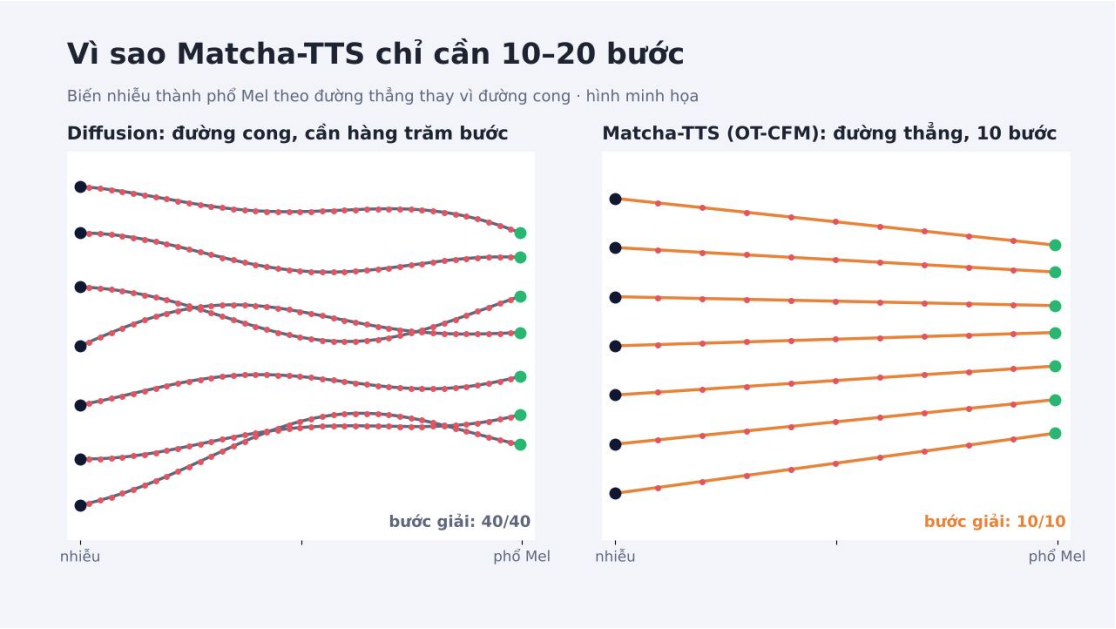
cắt lặng −30 dB, fade 10 ms

Đầu vào: văn bản thô từ khâu đọc hiểu. Đầu ra: tệp WAV 22,05 kHz. Mô hình nạp một lần, dùng chung cho mọi yêu cầu.

Một câu trả lời đi qua pipeline

Đầu vào	“Đáp án: (B) Chiến thắng Điện Biên Phủ ngày 07/05/1954.”
1 Chuẩn hóa	“Đáp án B: … ngày bảy tháng năm năm một nghìn chín trăm năm mươi tư.”
2 Phân cụm	“Đáp án B” + nghỉ 0,25 giây · “Chiến thắng … năm mươi tư” + nghỉ 0,40 giây
3 Tách thanh	“Chiến thắng” → c h i ê n + sắc · t h ă n g + sắc
4 Matcha	Phổ Mel 80 kênh × 412 khung ≈ 4,78 giây (20 bước)
5 HiFi-GAN	Sóng âm 105.472 mẫu ở 22.050 Hz
6 Xuất	Cắt lặng, làm mượt điểm nối → tệp WAV

Matcha-TTS: đi đường thẳng nên chỉ cần 10–20 bước



Video minh họa · bấm để phát

Mã hóa văn bản

đọc chuỗi âm vị và thanh điệu

Dự đoán thời lượng

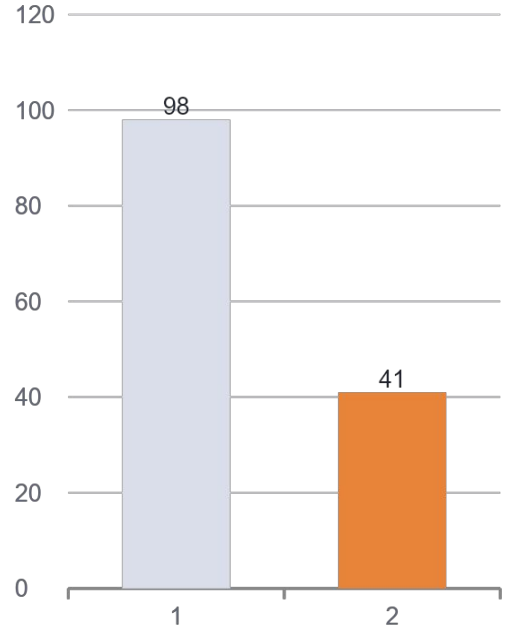
mỗi âm vị kéo dài bao lâu

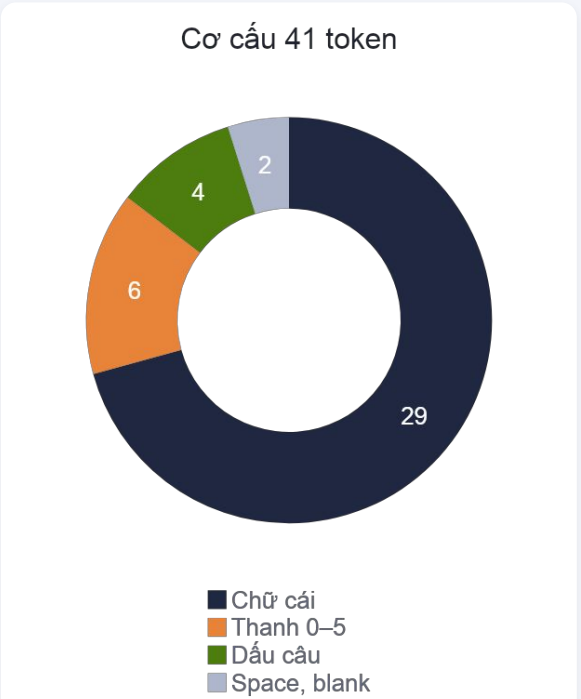
Bộ giải mã

biến nhiễu thành phổ Mel

Ít bước giải → chạy nhanh hơn thời gian thực trên CPU.

Tách thanh điệu thành token riêng: 98 → 41 ký hiệu



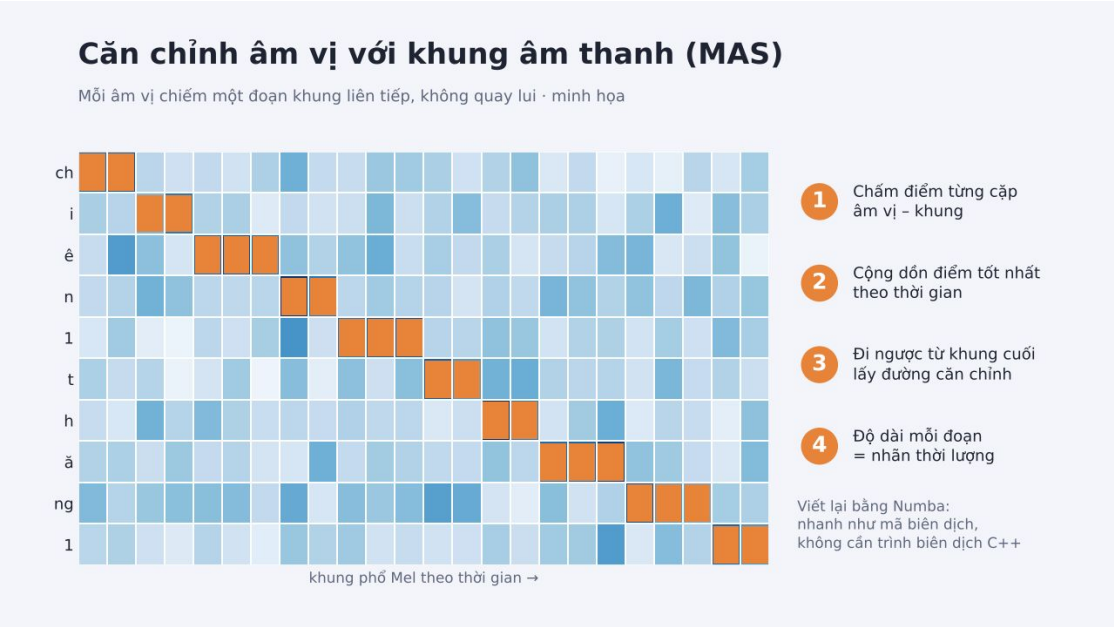


Tách dấu khỏi nguyên âm

hồ	h ô	2
nội	n ô i	5
gươm	g ư ơ m	0
thắng	t h ă n g	1
ửng	ư n g	3
mãi	m a i	4

Mọi nguyên âm cùng góp gradient cho 6 token thanh điệu.

MAS viết lại bằng Numba, không cần trình biên dịch C++



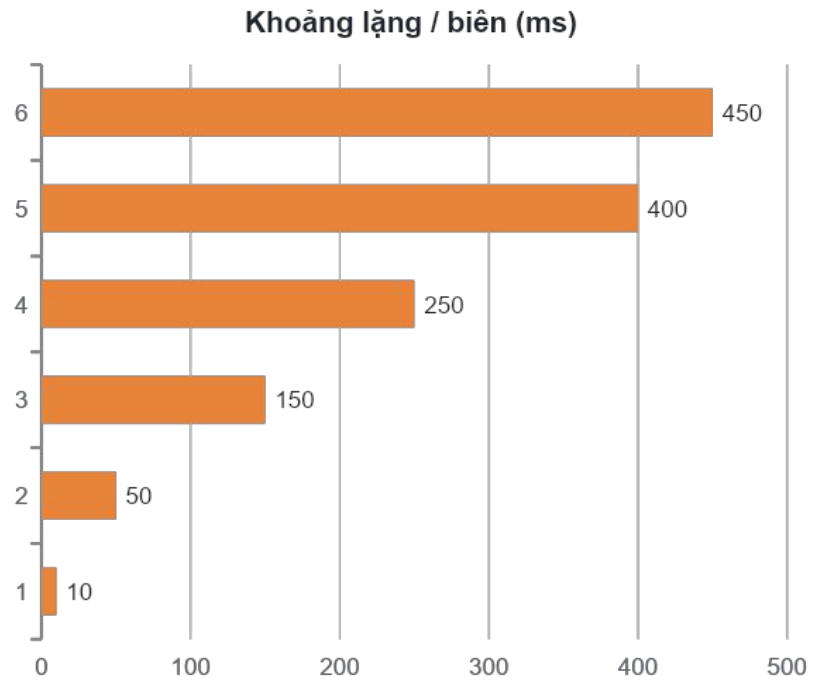
Video minh họa · bấm để phát

MAS dùng để làm gì

Ghép mỗi âm vị với một đoạn âm thanh liên tiếp, làm nhãn thời lượng khi huấn luyện.

- ✗ Bản gốc cần trình biên dịch C++, dễ lỗi khi đóng gói
- ✓ Bản mới nhanh tương đương
- ✓ Chạy trên Windows, Linux, macOS, Docker

Chèn khoảng lặng theo dấu câu, 4 engine dự phòng



Matcha-TTS — tự huấn luyện · cục bộ cốt lõi

VITS MMS — baseline đối sánh cục bộ

Edge-TTS — ưu tiên khi có mạng

gTTS — dự phòng cuối

Dự phòng 2 cấp: thiếu vocoder riêng → HiFi-GAN universal; lỗi máy hoặc mất mạng → engine kế tiếp.

Hai giai đoạn trên InfoRe1 (~25 giờ, một giọng nữ miền Bắc)

GĐ 1 · Acoustic

Matcha-TTS

150.000 bước

≈ 327 epoch

- Học chuyển giao từ checkpoint tiếng Anh
- Adam, lr 1e-4, EMA 0,9999

GĐ 2 · Vocoder

HiFi-GAN

50.000 bước

trên 4.000 cặp Mel nhân tạo

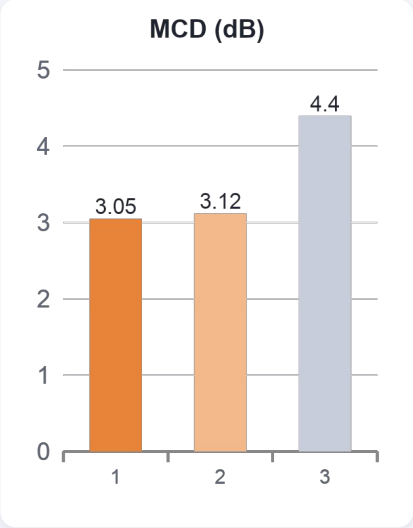
- Đóng băng Matcha, khử tiếng rè kim loại
- AdamW, lr 1e-4, huấn luyện đối kháng

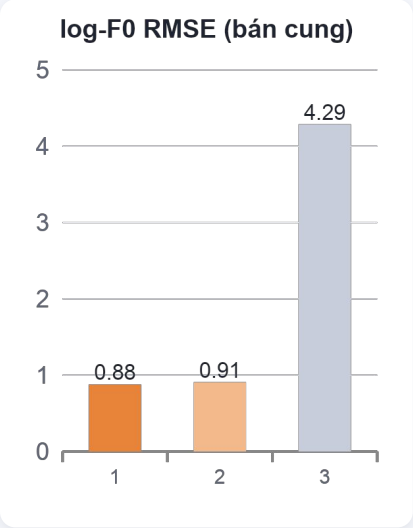
Chọn checkpoint bằng ASR

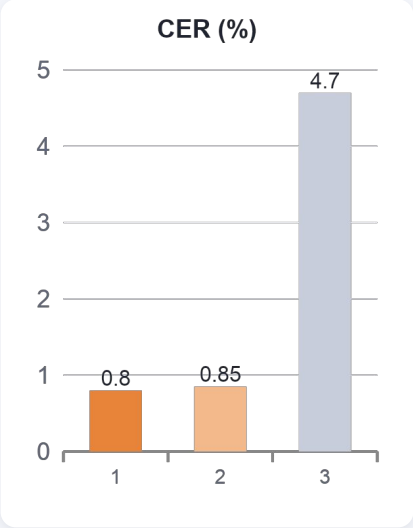
Loss giảm sớm nhưng giọng còn tốt lên lâu sau đó → chấm CER bằng PhoWhisper, chọn bước 150.000.

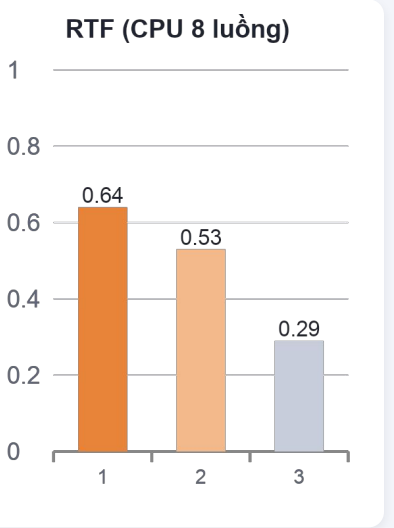
- Chuẩn hóa RMS −20 dBFS
- Mel 80 kênh, FFT 1024, hop 256
- Test: từ mẫu 14.800 trở đi
- Checkpoint resume qua phiên GPU 12 giờ

CER 0,8% sát giọng thật, RTF dưới 0,7 trên CPU









0,8%

CER · giọng thật 0,7% · VITS 4,7%

0,88

log-F0 bán cung · VITS 4,29 (4,87×)

3,05 dB

MCD · F0 RMSE 21,6 Hz

Đo trên 10 câu test (2–8 giây): chỉ báo xu hướng.

Cục bộ hay đám mây: đánh đổi chất giọng lấy quyền kiểm soát

Matcha-TTS

tự huấn luyện

- Khá ~3,5–3,8
- 18,2 triệu
- 100% offline
- Xử lý tại chỗ
- Miễn phí

VITS MMS

Meta, cục bộ

- Trung bình ~3,0
- 36,3 triệu
- 100% offline
- Xử lý tại chỗ
- Miễn phí

Azure / Edge-TTS

đám mây

- Xuất sắc ~4,5–4,7
- trăm triệu – tỷ
- Bắt buộc Internet
- Gửi văn bản ra ngoài
- Có thể tốn phí

MOS là ước lượng trong báo cáo TTS, chưa khảo sát người nghe. Số tham số: Matcha đếm từ checkpoint, VITS MMS theo Hugging Face. MCD/F0 có lợi cho Matcha vì tham chiếu chính là giọng InfoRe1.

PHẦN II · TRUY XUẤT NGỮ CẢNH

Truy xuất ngữ cảnh, Đọc hiểu và Hội thoại

Trình bày: Ngô Trí Huy

77,48%
Recall@1 dev (từ 71,45%)

1,48 triệu
đoạn Wikipedia, chạy trên CPU

0,468
F1 câu nói, bộ đọc mới (ViT5 0,446)

81,9%
hội thoại, held-out lần đầu

Trình bày: Ngô Trí Huy

Từ câu hỏi tự do đến đáp án: tìm đoạn văn rồi đọc hiểu

Bối cảnh

Người dùng chỉ nói câu hỏi, không kèm đoạn văn: hệ thống phải tự tìm

Kho từ bài đọc sách giáo khoa đến 1,48 triệu đoạn Wikipedia

ViMMRC 2.0 chỉ 5.273 câu trắc nghiệm, quá ít để học sinh đáp án

Các hướng tiếp cận đã khảo sát

Hướng / công trình	Điểm mạnh	Hạn chế với đề tài
BM25 · BM25S *Robertson & Zaragoza, 2009; Lù, 2024*	Nhanh, không cần huấn luyện	Chỉ khớp bề mặt từ
Truy xuất vector (DPR, mE5) *Karpukhin và cs., 2020; Wang và cs., 2024*	Hiểu tương đồng ngữ nghĩa	Chỉ mục lớn, tốn bộ nhớ
Xếp hạng lại cross-encoder *Nogueira & Cho, 2019; Chen và cs., 2024*	Chính xác nhất	Chậm, chỉ dùng cho vài ứng viên
Đọc hiểu: ViT5 (sinh) · XLM-R (trích span) *Raffel và cs., 2020; Phan và cs., 2022*	ViT5 sinh tự do · XLM-R trích đúng từ đoạn	**Chọn trích span, ViT5 làm đối chứng**

Nguồn: Báo cáo Retrieval–MRC, chương 1, 3 và tài liệu tham khảo

Ba cách truy xuất, đối sánh bộ đọc, từ chối khi thiếu căn cứ

THÁCH THỨC	GIẢI PHÁP CỦA NHÓM
BM25 mặc định chưa hợp tiếng Việt	**Tự cài BM25, chỉnh tham số trên tập train, thêm thưởng cụm từ**
Kho triệu đoạn phải chạy trên laptop	**Kho 2 tầng: KB + Wikipedia, vector đọc thẳng từ đĩa**
Không biết nên tin nguồn nào	**Reranker chấm chung, thưởng KB trên logit**
Dữ liệu đọc hiểu quá ít	**Tinh chỉnh ViT5, đối sánh 9 bộ đọc, chọn vi-mrc-large**
Câu nói tự nhiên, dễ trả lời bịa	**Tầng hội thoại và cổng từ chối theo điểm reranker**

Kết quả

77,48%
Recall@1 dev (từ 71,45%)

0,468
F1 câu nói (ViT5 0,446)

81,9%
hội thoại held-out

Trình bày: Ngô Trí Huy

Ba bài toán nối tiếp giữa STT và TTS

1 · Truy xuất

Tìm đoạn chứa đáp án trong kho hơn 1,48 triệu đoạn

2 · Đọc hiểu

Bộ đọc trích đáp án ngắn từ đoạn văn

3 · Hội thoại

Xã giao, câu nối tiếp, so sánh, đúng/sai; soạn câu trọn vẹn

Sáu giai đoạn của một lượt hỏi

Làm sạch
bỏ "ừm", lời mào đầu

→

Định tuyến
xã giao, phép tính, nối tiếp

→

Truy xuất
3 nguồn × top-3

→

Xếp hạng lại
bge-reranker

→

Đọc hiểu
vi-mrc-large

→

Soạn câu
hoặc từ chối

Giao diện chỉ gọi một dịch vụ hỏi đáp; truy xuất và đọc hiểu vẫn có dịch vụ riêng để kiểm thử từng khâu.

BM25, truy xuất vector, cross-encoder và bộ đọc

BM25 · khớp từ theo tần suất

- Từ của câu hỏi xuất hiện nhiều trong đoạn → điểm cao, nhưng có mức bão hòa
- Từ càng hiếm trong kho càng có trọng số lớn
- Đoạn quá dài bị trừ điểm để công bằng

ViT5-base · bộ đọc sinh (đối chứng)

Câu hỏi + đoạn
tối đa 512 token

→

ViT5
đọc và sinh

→

Đáp án ngắn
tối đa 64 token

multilingual-e5-small

Bi-encoder: mã hóa riêng câu hỏi và đoạn thành vector 384 chiều. Nhanh, chạy được cho 1,48 triệu đoạn.

bge-reranker-v2-m3

Cross-encoder: đọc cùng lúc cặp (câu hỏi, đoạn). Chính xác hơn, chậm hơn, chỉ chấm ≤ 9 ứng viên.

Trình bày: Ngô Trí Huy

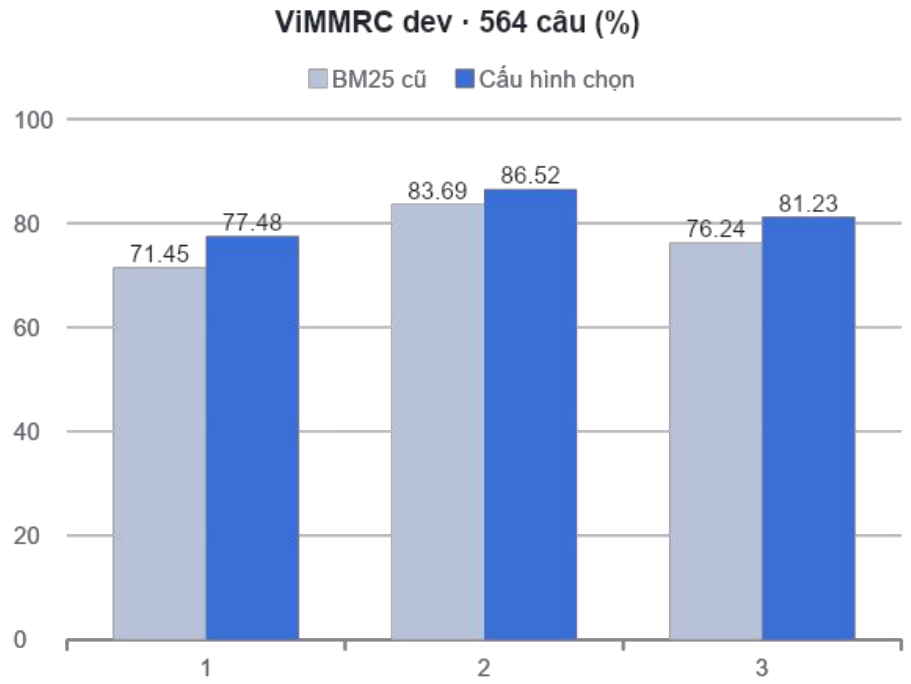
Chọn tham số trên train, đo dev một lần: R@1 +6 điểm

Tham số	Cũ	Chọn
k_1	1,5	2,1
b	0,75	1,0
Bỏ từ dừng câu hỏi	Không	Có
Thưởng bigram λ	0	0,4

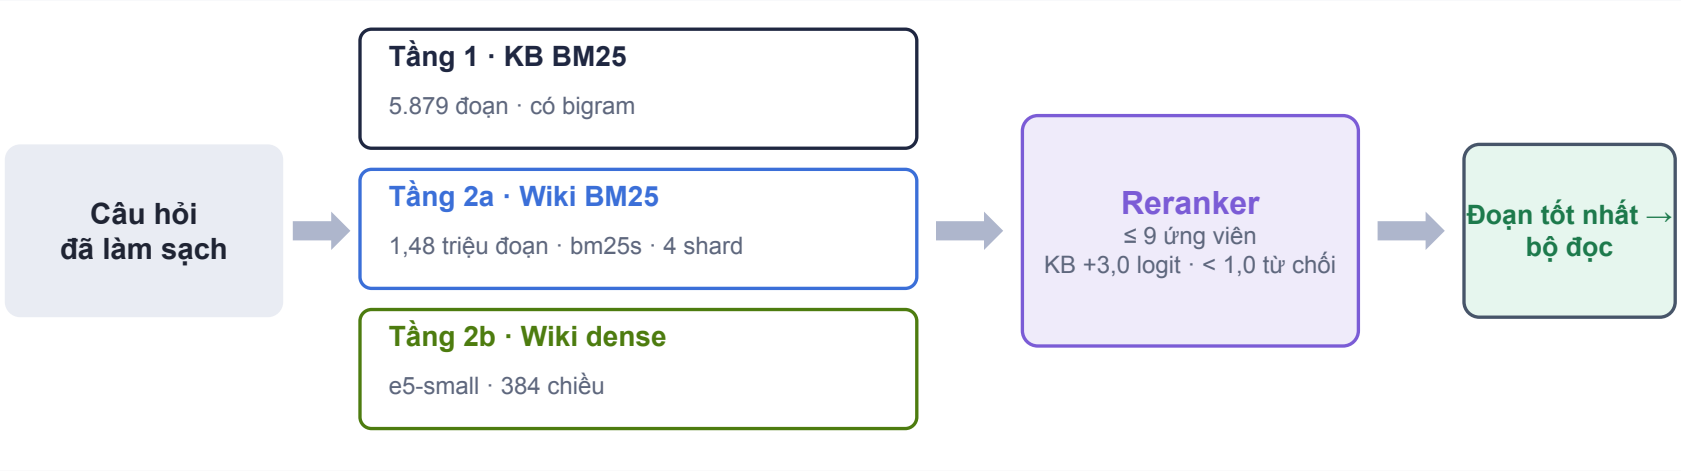
2,74×
nhanh hơn nhờ chỉ mục đảo

16
cấu hình thử trên 800 câu train

Không đọc tập test, nhãn A–D hay phương án trả lời khi chọn.



Ba nguồn × top-3, reranker chấm chung



≈ 1,1 GB

vector 1,48 triệu đoạn, đọc thẳng từ đĩa theo từng khối

+3,0 trên logit

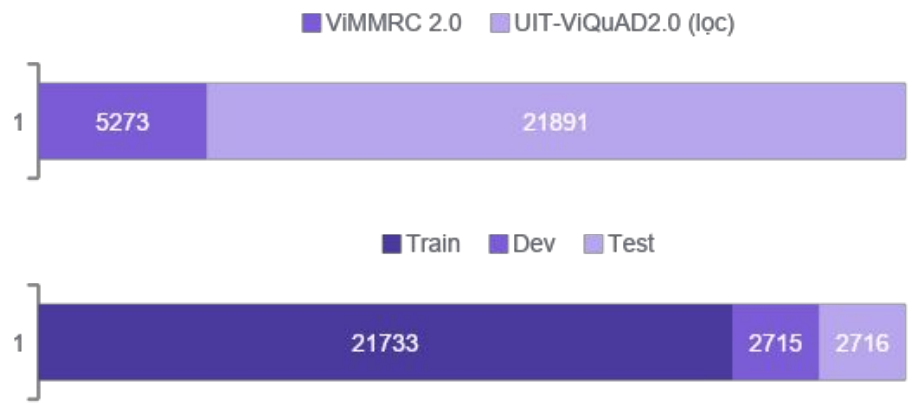
cộng vào logit, không cộng vào xác suất (0,86 + 0,25 > 1,00)

Văn bản trên đĩa

chỉ đọc nội dung khi đoạn lọt nhóm đầu

Trình bày: Ngô Trí Huy

Gộp ViMMRC 2.0 và UIT-ViQuAD2.0: 27.164 câu



27.164

câu hỏi (bỏ câu is_impossible)

Chia 80/10/10 theo đoạn văn, không theo câu hỏi. Kiểm tra tự động: không đoạn nào nằm ở hai tập.

Đoạn dài hơn 512 token

Đang dùng: cắt phần cuối. Đã thử giữ lại các khối chứa từ khóa câu hỏi nhưng chưa thấy cải thiện.

Trình bày: Ngô Trí Huy

Hai giai đoạn, dừng khi dev loss tăng



E1–E3: giai đoạn 1 (lr 3e-5); sau E3: giai đoạn 2 (lr 1e-5). Các điểm E3,3–E5 lấy trực tiếp từ log giai đoạn 2.

Quá khớp: EM chỉ nhích 42,95 → 43,24% nhưng dev loss tăng 0,69 → 0,84 trong khi train loss vẫn giảm.

GĐ 1

Dữ liệu hợp nhất — **42,95%**

3 epoch · lr 3e-5

GĐ 2

Huấn luyện tiếp (đang dùng) — **43,24%**

2 epoch · lr 1e-5

GĐ 3

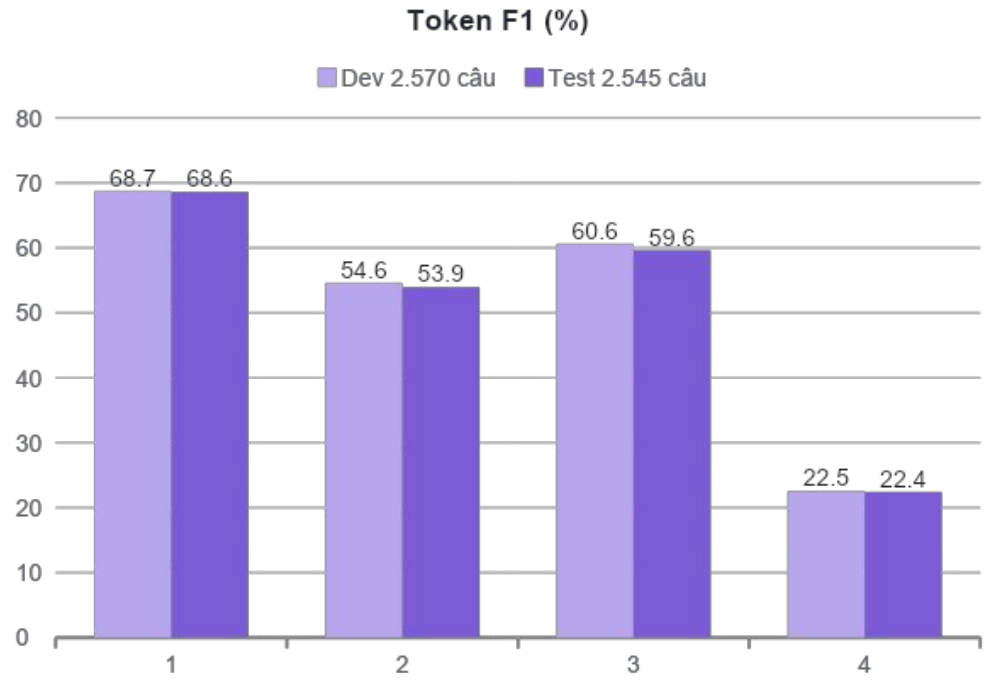
Chỉ ViMMRC (kết quả âm) — **10,82%***

4 epoch

*Dev EM tốt nhất · * đo trên dev ViMMRC riêng*

Đã sửa: lỗi giá trị đệm khi sinh câu, và lỗi tương thích phiên bản thư viện.

ViT5 · đọc đúng đoạn: F1 68,6 · toàn chuỗi: F1 53,9



41,05%

EM test, đưa đúng đoạn (2.716 câu)

66,55%

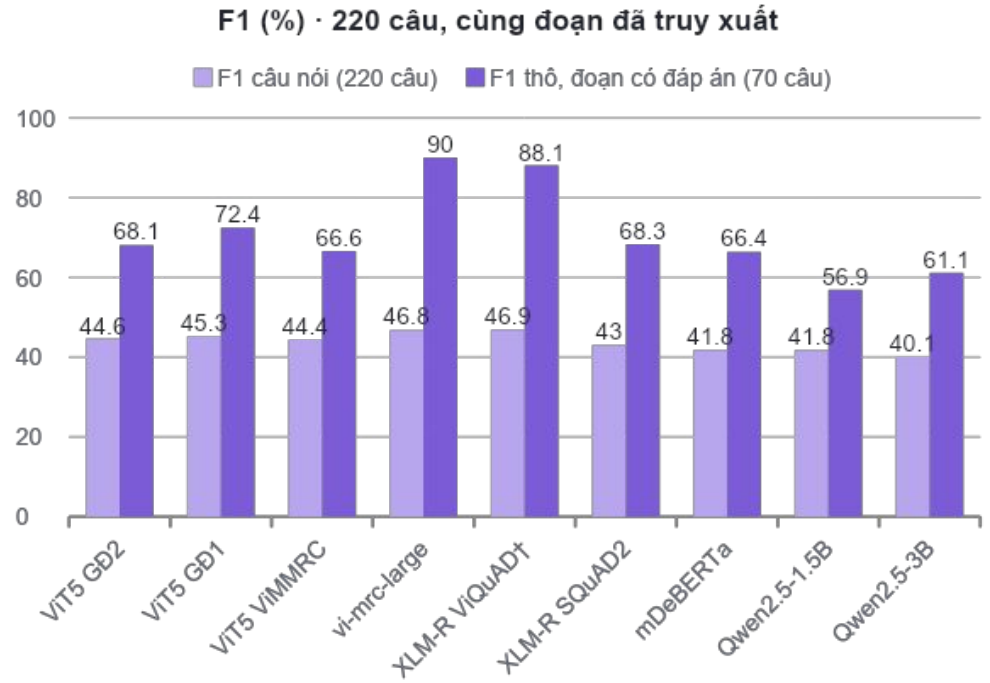
token F1 test, đưa đúng đoạn

−14,7

điểm F1 mất do truy xuất sai đoạn

F1 cao hơn EM ~25 điểm: đáp án tham chiếu là cụm dài, mô hình nói khác chữ nhưng đúng ý.

Chín bộ đọc, cùng đoạn văn: trích span thắng khi đoạn có đáp án



90,0%

F1 thô, đoạn có đáp án · ViT5 68,1%

0,468

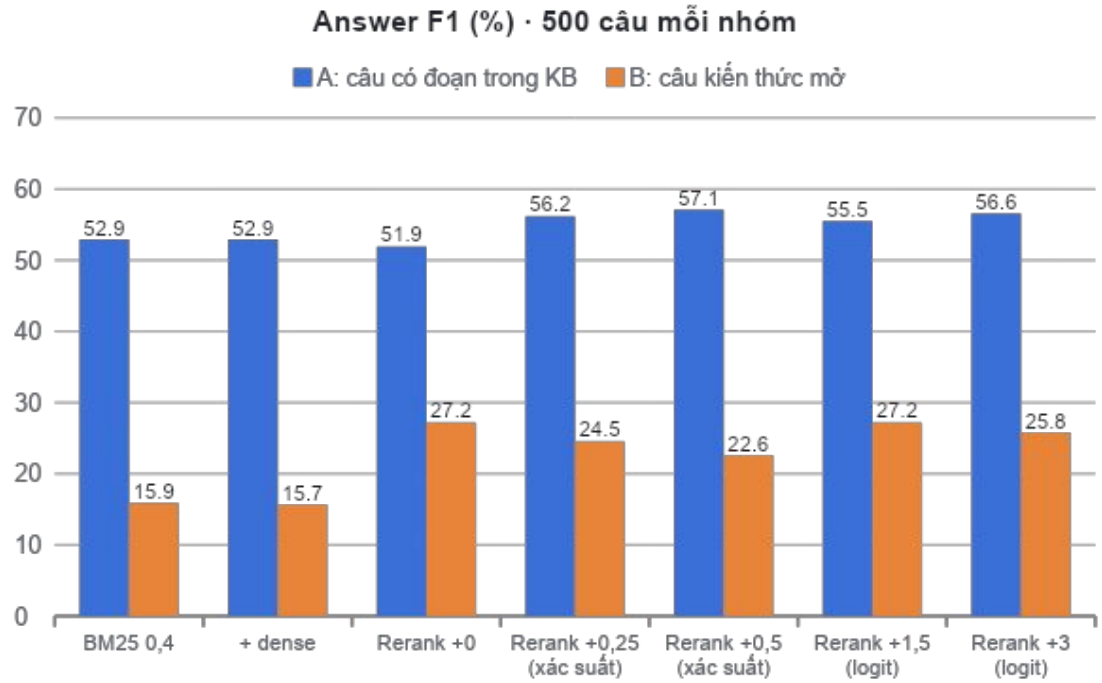
F1 câu nói, 220 câu · ViT5 0,446

0,62 s

mỗi câu trên CPU · ViT5 0,44 s

Chênh 0,02 chưa chắc có ý nghĩa; bằng chứng nằm ở 70 câu có đáp án và 100 câu test. Giấy phép: phi thương mại.

Thưởng KB trên logit: giữ nhóm A, ít mất nhóm B hơn thưởng xác suất



52,9 → 56,6

15,9 → 25,8

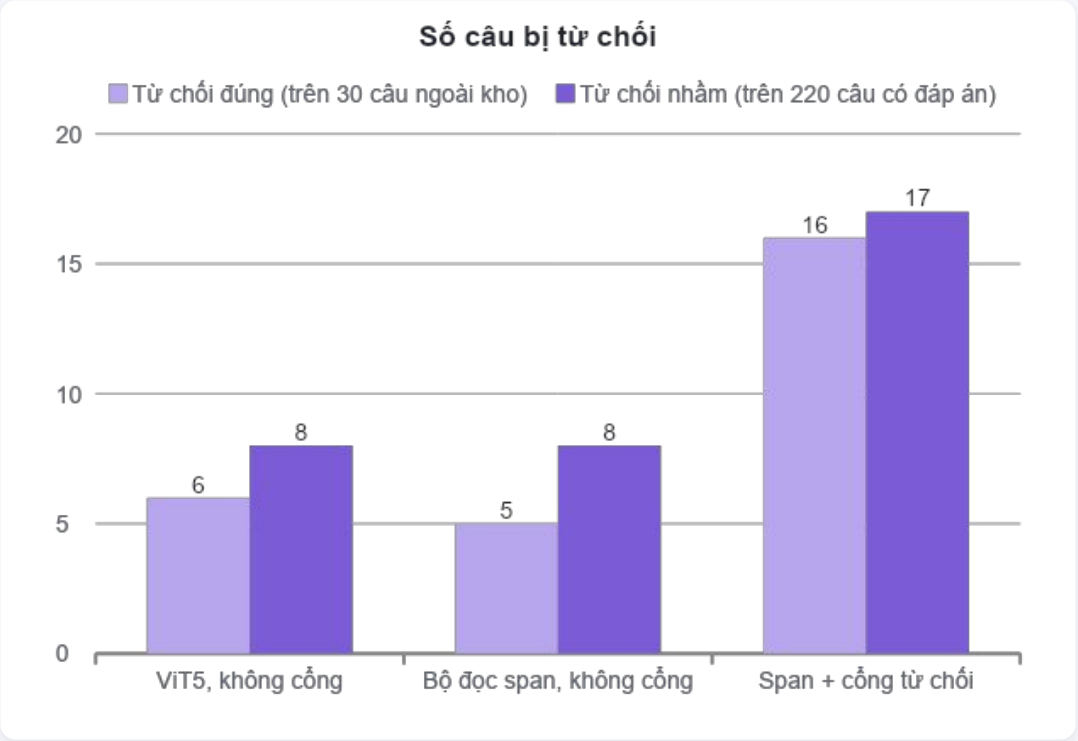
Nhóm A / nhóm B so với luật ngưỡng BM25 0,4

Thử LLM 9B (Ollama)

- Mục tiêu 80–90% EM: không hướng nào tới gần
- 50 câu: ViT5 và LLM 9B tương đương; 16/50 câu cả hai sai
- Chọn F1 làm thước đo chính

Trình bày: Ngô Trí Huy

Điểm reranker < 1,0 thì từ chối: 5 → 16 trên 30 câu ngoài kho



5 → 16 /30

câu ngoài kho được từ chối đúng

+9

câu có đáp án bị từ chối thêm (5/9 vốn sai)

−0,007

F1 đầu cuối (FP32): 0,4583 → 0,4512; INT8 triển khai 0,4421

Ngưỡng chọn trên chính 250 câu đo. 14 câu ngoài kho vẫn bị trả lời; vài câu nhãn "không trả lời được" thực ra Wikipedia trả lời được.

Regex + heuristic, không cần thêm mô hình

Làm sạch câu

bỏ từ đệm, lời mào đầu

Xã giao

chào hỏi, phép tính bằng chữ

Nhớ ngữ cảnh

hiểu câu nối tiếp trong phiên

Soạn câu

câu trọn vẹn hoặc từ chối

Ví dụ biến đổi

“Ừm cho mình hỏi là thủ đô Nhật Bản là gì vậy bạn”	**thủ đô Nhật Bản là gì**
(lượt sau) “còn Hàn Quốc thì sao?”	**Thủ đô của Hàn Quốc là gì**
Bộ đọc trả “Tokyo”	**Thủ đô của Nhật Bản là Tokyo.**
“một trăm trừ ba mươi lăm bằng mấy”	**trả lời ngay, không gọi mô hình**

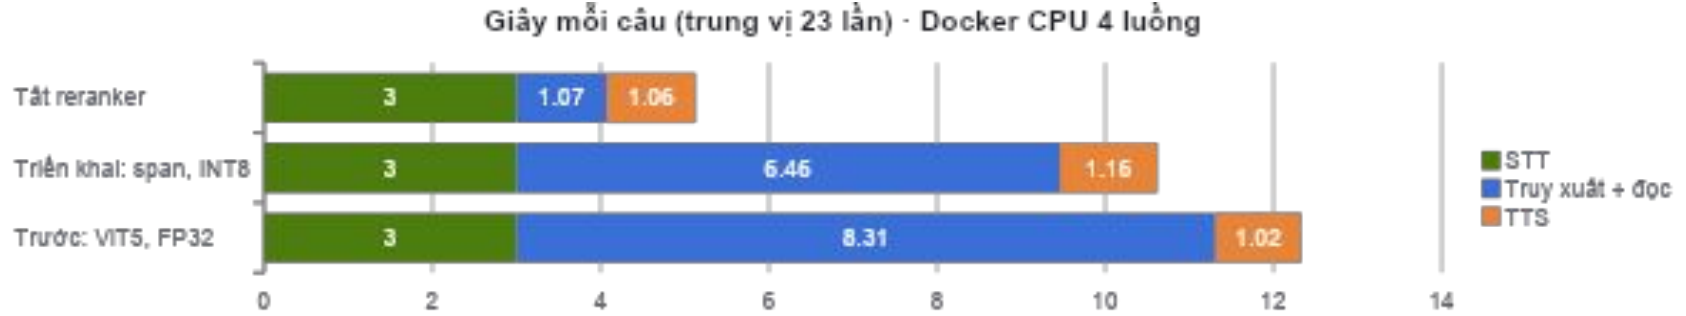
81,9% → 97,2%

Held-out 72 mục: lần chạy đầu → sau sửa lỗi chung. 81,9% là con số khách quan.

Đo offline với kho mẫu 75 đoạn và bộ đọc heuristic, chưa phải kho thật + bộ đọc thật.

Trình bày: Ngô Trí Huy

Truy xuất chiếm hơn một nửa; INT8 giảm tổng 14%



Bigram Wiki không vừa RAM

→ bm25s + dense + reranker

Điểm 2 tầng không so được

→ reranker chấm chung

PyTorch tranh luồng CPU

→ giới hạn 4 luồng

Tiếp theo: tách từ ghép cho BM25 · tinh chỉnh dense encoder · đo hội thoại đa lượt trên kho thật. Câu kiến thức mở hiện F1 25,8.

Trình bày: Ngô Trí Huy

Trả lời dài kèm nguồn: F1 phạt câu dài

Câu bằng chứng

câu chứa đáp án, ≤ 40 từ

Nêu nguồn

Wikipedia, bài đọc ViMMRC, kho chọn lọc

Trường source

/api/ask trả kèm nguồn

Bật bằng env

DIALOGUE_DETAIL=1 (Docker)

Số đo chế độ dài so với chế độ ngắn

Độ dài câu trả lời (từ)	**21,6 → 52,4**
Token F1 (phạt câu dài)	**0,4421 → 0,2945**
Token recall, chế độ dài	**0,651**
Đoạn nguồn chứa token đáp án	**0,83**

0,83 nguồn

Tỷ lệ token đáp án chuẩn nằm trong đoạn được dẫn nguồn (ood 0,90; hard 0,68; test 0,78).

F1 giảm vì câu dài hơn, chưa phải vì sai. Chưa có điểm chấm tay: cần hai người chấm (docs/human_eval_protocol.md).



PHẦN III · NHẬN DẠNG GIỌNG NÓI (STT)

Nhận dạng tiếng nói (Speech-to-Text)

Trình bày: Huỳnh Công Lương

13,77%
WER test (gốc 36,76%)

0,73%
tham số được học (LoRA)

50 giờ
VietSpeech, train 46 giờ

241 MiB
CTranslate2 INT8 chạy CPU

Trình bày: Huỳnh Công Lương

Nhận dạng câu hỏi tiếng Việt: dùng sẵn hay tinh chỉnh?

Bối cảnh

- Câu hỏi nói tự nhiên: có từ đệm, tên riêng, con số
- Nhiều vùng giọng, nhiều nguồn ghi âm khác nhau
- Phải chạy CPU cùng lúc với 3 mô hình khác

Các hướng tiếp cận đã khảo sát

Hướng / công trình	Điểm mạnh	Hạn chế với đề tài
Whisper-small gốc *Radford và cs., 2023*	Đa ngôn ngữ, dùng ngay	WER 36,76% trên test của nhóm
Tinh chỉnh toàn bộ *fine-tune đầy đủ*	Sát dữ liệu nhất	Cập nhật ~244 triệu tham số, nặng với GPU 16 GB
ViWhisper-small *NhutP, 2024*	Đã tinh chỉnh tiếng Việt	Có thể đã học VietSpeech, không đối chứng độc lập được
Whisper + LoRA *Hu và cs., 2022*	Chỉ học 0,73% tham số	**Chọn · vẫn tốn bộ nhớ activations**

Nguồn: Báo cáo STT, mục 1–2, 8 và tài liệu tham khảo [1]–[5]

Whisper-small + LoRA, dữ liệu sạch và chạy INT8 trên CPU

THÁCH THỨC	GIẢI PHÁP CỦA NHÓM
GPU chỉ 16 GB, không đủ tinh chỉnh toàn bộ	**LoRA trên whisper-small, chỉ học 1,77 triệu tham số**
VietSpeech 131 GB, quá lớn để tải hết	**Stream có chọn lọc: 20 giờ rồi mở rộng 50 giờ**
Nguy cơ rò rỉ giữa train và test	**Tách tập theo nội dung lời, khóa cố định tập test**
Phải chạy nhanh trên CPU	**Gộp LoRA, lượng tử INT8, chạy bằng faster-whisper**

Kết quả

13,77%
WER test (gốc 36,76%)

6,67%
CER test (gốc 19,43%)

241 MiB
mô hình chạy CPU

Whisper-small + LoRA: học ít tham số, giữ mô hình nền

Vị trí trong chuỗi

Ghi âm
16 kHz mono

→

Whisper
tinh chỉnh LoRA

→

Văn bản
→ Retrieval

Sai tên riêng, con số, từ nghi vấn → đổi nghĩa câu hỏi ở các khâu sau.

openai/whisper-small

- Encoder–decoder trên log-Mel spectrogram
- ≈ 244 triệu tham số, đã tiền huấn luyện đa ngôn ngữ
- Đặt ngôn ngữ tiếng Việt, chế độ chép lời

Cập nhật hạng thấp (LoRA)

Trọng số gốc · giữ nguyên + **Phần nhỏ · được học**

1.769.472
tham số trainable

≈ 0,73%
tổng tham số sau khi gắn

gắn vào attention | **hạng 16** | **alpha 32** | **dropout 0,05**

LoRA giảm tham số và trạng thái optimizer cần lưu, nhưng không giảm bộ nhớ activations.

Trình bày: Huỳnh Công Lương

VietSpeech: stream có chọn lọc, tách tập theo transcript

> 1.100 giờ
tiếng nói

1.026.047
mẫu

16 kHz
tần số lấy mẫu

≈ 131 GB
nếu tải trọn bộ

Streaming và lọc mẫu

Stream
không tải trọn bộ

→

Giải mã
lưu thành FLAC

→

Lọc
0,5–30 giây, bỏ rỗng

→

Danh sách
đường dẫn, lời, thời lượng

Tách tập theo nội dung lời (cố định)

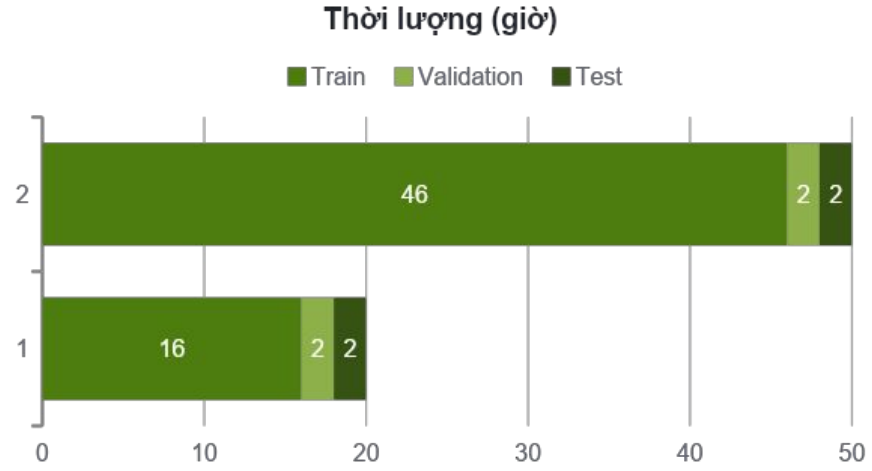


Câu có cùng nội dung lời luôn rơi vào cùng một tập, tránh rò rỉ. Chưa tách theo người nói.

Bộ 20 giờ	Số mẫu	Giờ
Train	14.393	16,00
Validation	1.797	2,00
Test	1.802	2,00

Trình bày: Huỳnh Công Lương

Từ 20 lên 50 giờ: chỉ thêm train, khóa nguyên tập đánh giá



+26.819
mẫu train mới (≈ +30 giờ)

44.811
tệp audio, kiểm tra đọc được hết

Hậu kiểm trước khi train

- Val/test giống hệt bộ 20 giờ
- Giao nhóm transcript giữa 3 tập = 0
- Hard-link FLAC cũ, chỉ stream mẫu mới
- Thư mục output riêng, giữ bản 20 giờ

Run 50 giờ đổi cả dữ liệu, số step và chế độ dừng: không phải ablation chỉ thay dữ liệu.

Cấu hình tinh chỉnh trên một GPU 16 GB

Batch hiệu dụng **4 × 8 = 32**	Learning rate **1×10^{-4}**	Warmup **5%**	Precision **BF16**
Epoch tối đa **3**	Eval / save **mỗi 250 step**	Chọn checkpoint **val WER thấp nhất**	Early stopping **patience 3 · 0,2**

Một bước tinh chỉnh

Âm thanh
16 kHz → phổ Mel

→

Nhãn
lời chép tay

→

Học
chỉ cập nhật LoRA

→

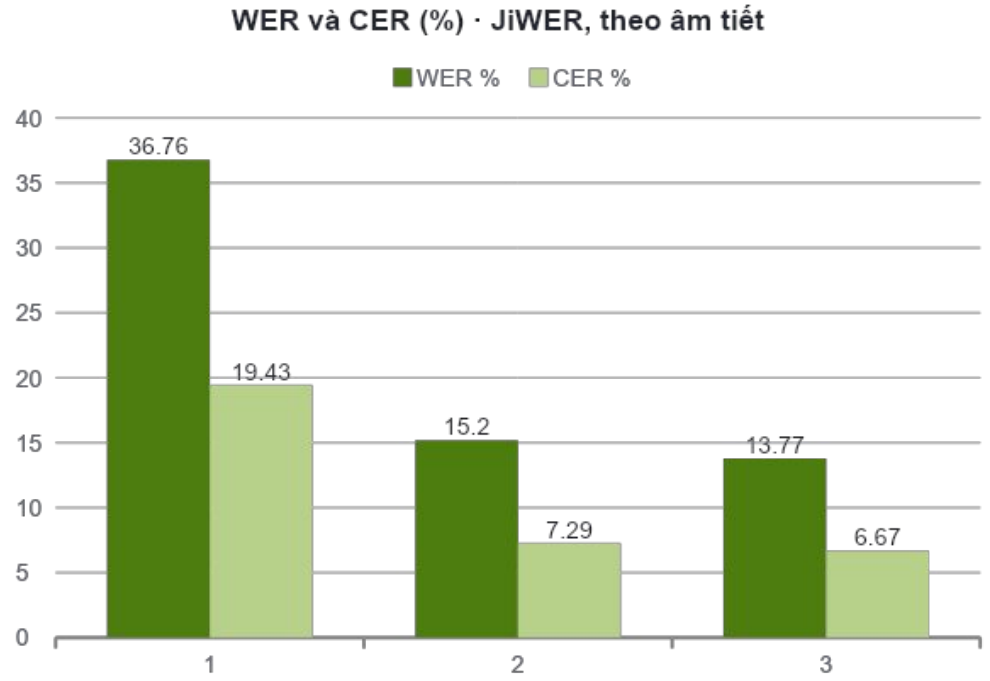
Chọn
WER validation

1.350
step · run 20h (best 1.250)

2.750
step · run 50h (best 2.750)

Một GPU RTX 5060 Ti 16 GB, chạy trên WSL2

WER giảm 62,6% tương đối trên 1.802 mẫu test cố định



−62,56%

WER tương đối so với gốc

6,67%

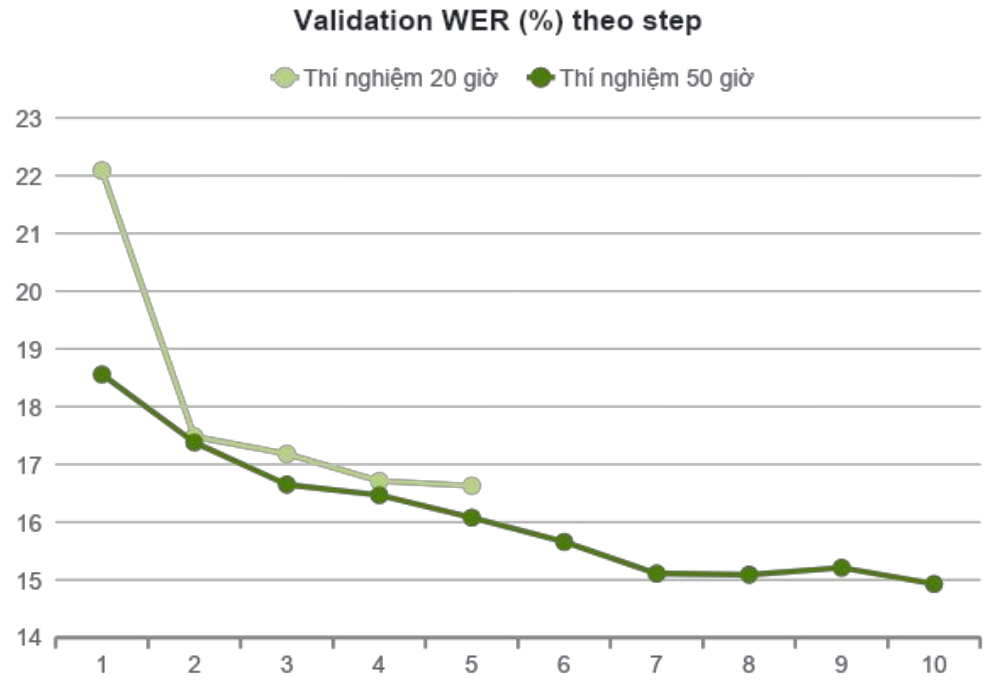
CER bản 50 giờ (gốc 19,43%)

−9,47%

WER thêm khi tăng 16 → 46 giờ train

ViWhisper-small đạt 0,82% nhưng có thể đã học VietSpeech, chỉ dùng làm mốc. Mỗi quy mô mới có 1 run.

Validation WER và early stopping tại step 2.750



patience 3 · ngưỡng 0,2 điểm tuyệt đối

2.000	15,11%	−0,47	0
2.250	15,09%	−0,02	1
2.500	15,21%	tăng	2
2.750	14,93%	−0,16	3 → dừng

2.750 vừa là best (14,93%) vừa là điểm dừng: 3 lần liên tiếp không vượt best quá 0,2 điểm. Chỉ kết luận hội tụ theo quy tắc đã đặt.

Trình bày: Huỳnh Công Lương

Merge, lượng tử INT8 và đưa lên API trên CPU

Bản tốt nhất
theo WER validation

→

Gộp LoRA
vào mô hình gốc

→

Lượng tử INT8
CTranslate2

→

241,48 MiB
gọn, chạy CPU

→

Dịch vụ web
faster-whisper

Cấu hình suy luận

CPU · INT8 | beam 5 | VAD bật | tiếng Việt

Thứ tự chọn mô hình

Cấu hình riêng → bản 50 giờ → bản 20 giờ → Whisper gốc

Nạp mô hình một lần, xử lý lần lượt từng yêu cầu, tự xóa tệp tạm.

Dịch vụ nhận dạng: gửi tệp ghi âm, nhận văn bản

Tệp ≤ 25 MiB · WAV, MP3, FLAC, OGG, WebM

400	413	415	422	500
rỗng	quá lớn	sai MIME	không lời	lỗi

WER/CER là của checkpoint Transformers. Bản INT8 đo riêng trên 135 câu InfoRe1 ngoài miền: WER 16,09%, CER 6,90%, RTF 0,22 (Whisper-small gốc INT8: 27,51%).

Trình bày: Huỳnh Công Lương

Lỗi tên riêng ở STT kéo Recall@1 xuống 10 điểm

100 câu ViMMRC dev đọc bằng giọng tổng hợp

69,0% → **59,0%**

Recall@1: văn bản gốc → văn bản STT (WER 8,28%, giọng gTTS)

Hai Bà Trưng	hai bà trương
Hai Bà Trưng	hay bà chân
Côlômbô	colombo

Nguồn: báo cáo đánh giá trong mã nguồn, chưa có trong báo cáo PDF

Sự cố kỹ thuật đã xử lý

Dữ liệu 131 GB	chỉ stream phần cần
Xung đột thư viện âm thanh	cố định phiên bản
Thiếu thư viện GPU trên Windows	máy chủ chạy CPU INT8
Lỗi đa tiến trình sau khi nạp GPU	xử lý dữ liệu trước
Ổ C còn 5,2 GB, ổ ảo chỉ đọc	dọn cache, thu gọn ổ ảo

Tiếp theo

- Thu 100–300 câu hỏi ViMMRC từ người thật, nhiều giọng
- Đo STT bộ test 1.802 câu (INT8 đã đo trên InfoRe1)

PHẦN IV · TÍCH HỢP HỆ THỐNG

Tích hợp full-stack, kiểm thử và tổng kết

Trình bày: Cả nhóm

1 tiến trình
FastAPI gồm STT, QA, TTS, web

144 / 144
bài kiểm thử tự động đạt

110 câu
ngoài tập dữ liệu, 6 chủ đề

≈ 10,6 s
mỗi câu trên CPU (≈ 5,1 s nhanh)

Một máy chủ FastAPI, tự lùi khi thiếu tài nguyên

Một tiến trình chứa toàn bộ hệ thống

- **Nhận dạng giọng nói**
- **Quản lý hội thoại**
- **Truy xuất 2 tầng**
- **Đọc hiểu**
- **Tổng hợp giọng nói**
- **Giao diện web**

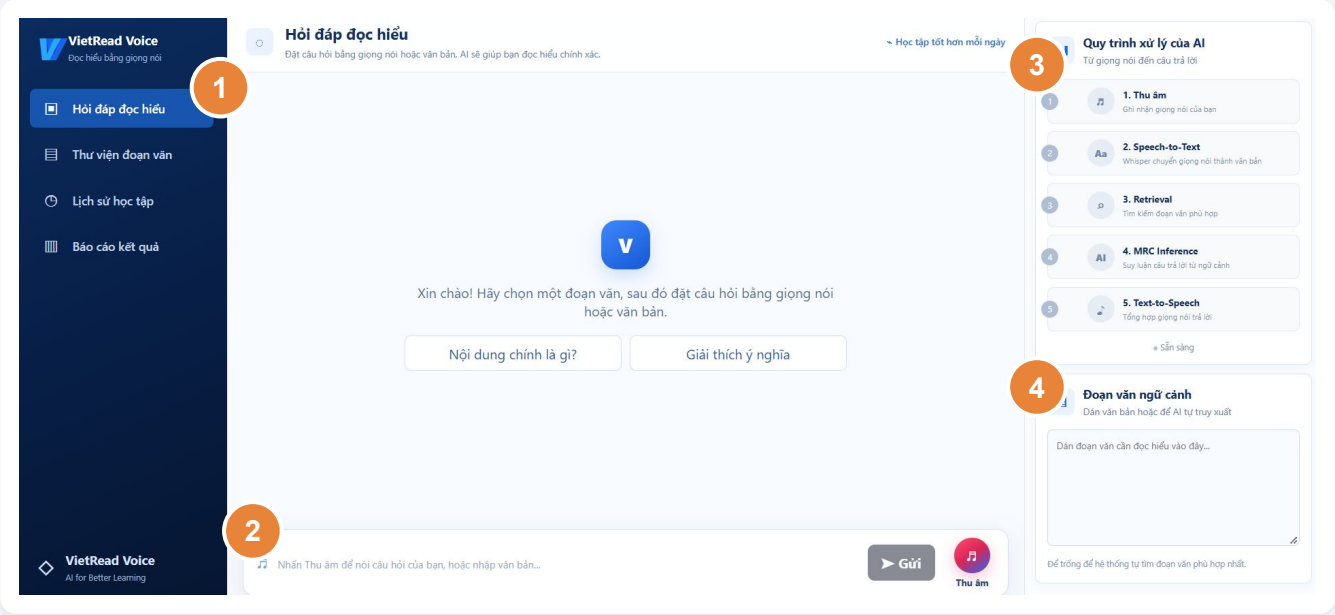
Tự lùi khi khởi động

Thiếu kho Wikipedia → dùng kho nhỏ hơn, tới kho mẫu 75 đoạn
Thiếu checkpoint bộ đọc → dùng bản trước, tới bộ đọc đơn giản

7 dịch vụ

- Kiểm tra trạng thái
- Nhận dạng giọng nói
- **Hỏi đáp** — giao diện dùng
- Xóa phiên hội thoại
- Truy xuất (kiểm thử)
- Đọc hiểu (kiểm thử)
- Tổng hợp giọng nói

Giao diện web: hỏi bằng giọng nói, theo dõi từng bước



1 · Điều hướng

hỏi đáp, thư viện đoạn văn, lịch sử, báo cáo

2 · Khung hỏi đáp

gõ câu hỏi hoặc nhấn Thu âm

3 · Quy trình xử lý

5 bước sáng dần khi hệ thống chạy

4 · Đoạn văn ngữ cảnh

dán đoạn văn, hoặc để trống để tự tìm

1 · Thu âm | 2 · Speech-to-Text | 3 · Retrieval | 4 · MRC | 5 · Text-to-Speech

Ảnh chụp giao diện thật

Docker hai tầng, khởi chạy bằng một lệnh

Tầng 1 · Dựng giao diện

Node 22

- Cài thư viện giao diện
- Biên dịch ứng dụng Angular

Tầng 2 · Chạy hệ thống

Python 3.11

- Thư viện xử lý âm thanh
- PyTorch bản CPU
- Nạp sẵn e5-small và reranker
- Tự kiểm tra mỗi 30 giây

Một lệnh khởi chạy, mở trình duyệt ở cổng 8090

≈ 10,6 s
bật reranker

≈ 5,1 s
tắt reranker

Giới hạn 4 luồng CPU

tránh các mô hình tranh nhau CPU

Ngưỡng chống bịa 0,34

từ chối khi đoạn văn thiếu căn cứ

Bật/tắt reranker

chọn chính xác hay nhanh

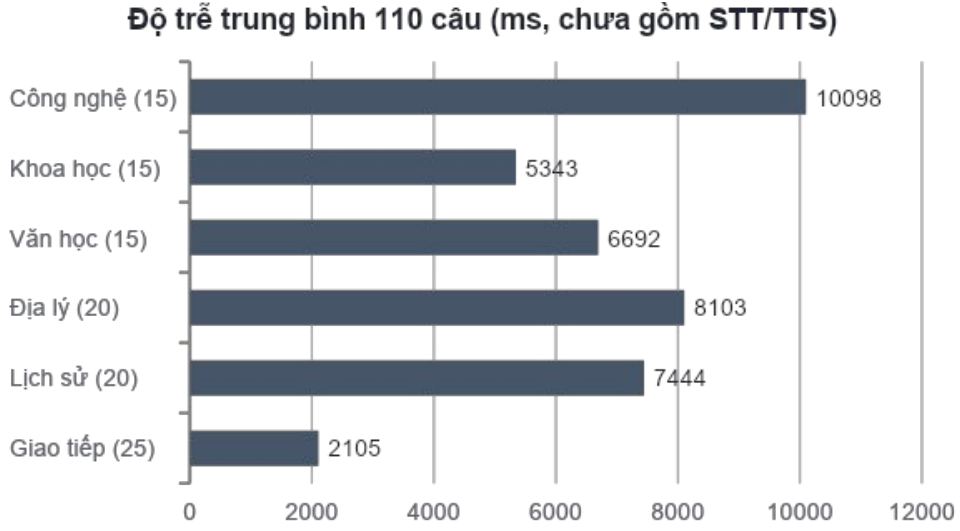
144 bài kiểm thử tự động và bộ 110 câu ngoài dữ liệu

144 / 144

bài kiểm thử tự động đạt (pytest, 2026-11-08)

- STT · 10
- Truy xuất · 17
- Đọc hiểu · 20
- TTS · 18
- Hội thoại · 45
- API, web · 34

Chốt hồi quy hội thoại: dev ≥ 95%, held-out ≥ 90%



100% là tỷ lệ trả về câu hoàn chỉnh cho TTS (110 câu + 35 câu khó + 4 kịch bản 30 lượt), không phải độ chính xác. Độ trễ đo ngày 8/11 qua Docker CPU (cấu hình triển khai): trung vị 6,5 s, trung bình 6,3 s; nhóm giao tiếp trả lời ngay (trung vị 27 ms).

Một câu hỏi đi qua cả 4 chặng



Video minh họa luồng · thay bằng video demo thật nếu có

Hỏi nối tiếp

“Chiến dịch đại phá quân Thanh năm 1789 do ai chỉ huy?”

→ “Ông ấy lên ngôi ở đâu?”

Hệ thống hiểu “ông ấy” là Quang Trung.

Chống bịa đặt

Câu hỏi ngoài kho → hệ thống từ chối lịch sự thay vì đoán.

Kết quả đạt được ở từng phân hệ

STT	Whisper LoRA 50 giờ · INT8	**13,77%** WER	**6,67%** CER	**−62,6%** WER tương đối
Truy xuất	BM25 chỉnh + Wiki + reranker	**77,48%** R@1 dev	**56,6** F1 câu trong kho	**25,8** F1 câu mở
Đọc hiểu	vi-mrc-large (chọn qua đối sánh)	**0,468** F1 câu nói	**16/30** câu ngoài kho từ chối đúng	**81,9%** hội thoại held-out
TTS	Matcha-TTS + HiFi-GAN	**0,8%** CER	**0,88** log-F0 bán cung	**0,53–0,64** RTF CPU
Hệ thống	FastAPI + Angular + Docker	**144/144** kiểm thử	**≈ 10,6 s** mỗi câu CPU	**≈ 5,1 s** chế độ nhanh

Hướng tiếp theo

- Bộ câu hỏi thu âm người thật
- GPU / INT8 / ONNX giảm trễ
- Tách từ ghép cho BM25
- TTS đa giọng Bắc–Trung–Nam

VIMMRC VOICE Q&A

Em xin chân thành cảm ơn Thầy!

Kính mời Thầy đặt câu hỏi và góp ý

Ngô Trí Huy · Huỳnh Công Lương · Trương Hoàng Duy

